MEB Kaynaklı, RAG Destekli Sesli AI Asistan

Öğrencinin kendi ders kitabından konuşarak cevap alabildiği bağımsız cihaz

Staj projesi · Proje özeti ve teknik rapor

---

1. Proje nedir

Öğrenci cihazdaki panele **basılı tutar, sorusunu sorar, bırakır.** Birkaç saniye içinde sesli cevabı duyar ve ekranda cevabın **hangi üniteden** geldiğini görür.

Cevap genel bir dil modelinden değil, **öğrencinin kendi sınıfına ait MEB ders kitabından** üretilir. Konu kitapta yoksa sistem uydurmaz; bulamadığını söyler. Projenin ayırt edici iddiası budur: *doğru cevap değil, kaynağı gösterilebilir cevap.*

> **Neden bu problem önemli**
>
> Genel amaçlı sohbet botları öğrenciye müfredat dışı, bazen yanlış bilgi verebiliyor ve öğretmen bunu doğrulayamıyor. Cevabı belirli bir kitabın belirli bir ünitesine bağlamak, hem **uydurmayı engelliyor** hem de öğretmene **denetlenebilirlik** kazandırıyor.

2. Bir turun akışı

1. Kayıt	2. STT	3. Arama	4. Cevap	5. Ses
Cihaz mikrofonu 16 kHz PCM yakalar, WebSocket'ten akıtır	Ses yazıya çevrilir (ders terimleri ipucu olarak verilir)	Sınıf/ders filtresiyle hibrit arama; ilgili parçalar bulunur	LLM yalnızca bu parçalara dayanarak cevap üretir	Cevap cümle cümle seslendirilip anında cihaza gönderilir

Zincirin tamamı **akışlıdır**: cevabın tamamı beklenmez. İlk cümle biter bitmez seslendirilip yola çıkar, kalan cümleler üretilirken cihaz zaten konuşmaktadır. İlk sese kadar geçen süre bu sayede **11 saniyeden 3 saniyeye** indi.

3. Sistem mimarisi

Katman	İçerik
Cihaz	ESP32-S3 · dokunmatik ekran, mikrofon, hoparlör. Kayıt, çalma, arayüz ve WebSocket istemcisi.
Backend	Tek FastAPI süreci. WebSocket ağ geçidi, tur orkestrasyonu, sağlayıcı adapterleri, panel.
Bilgi tabanı	Qdrant vektör veritabanı — MEB kitapları parçalanmış, her parça sınıf/ders/ünite bilgisiyle etiketli.
Kayıt	PostgreSQL — her tur: soru, cevap, dayandığı kaynaklar, aşama gecikmeleri, kullanılan model ayarları.

Panel	Tarayıcıdan canlı izleme, geçmiş sohbetler ve çalışma anında ayar değişimi.

Bilgi tabanı

12 sınıf düzeyi ve her sınıfta o sınıfa ait dersler indekslendi; toplam **8.577 metin parçası**. Her parça, ait olduğu ünite ve konu başlığıyla ("breadcrumb") birlikte saklanıyor — cevabın kaynağını gösterebilmenin temeli bu.

4. Kritik teknik kararlar

Neden hibrit arama

Yalnızca anlamsal (vektör) arama, "yoğunluk" gibi **tam terim** aramalarında zayıf; yalnızca kelime tabanlı arama ise farklı ifade edilmiş soruları kaçırıyor. İkisi birlikte çalıştırılıp sonuçlar sıralama tabanlı birleştiriliyor (RRF).

> **Ölçülmüş bir hata**
>
> Kelime araması kolunun Türkçe yerine varsayılan İngilizce kök bulucuyla çalıştığı fark edildi: üretilen indekslerin yalnızca **%42'si** tutuyordu, yani aramanın yarısı sessizce boşa çalışıyordu. Hiçbir hata mesajı yoktu — yalnızca sonuçlar biraz kötüydü.

Uydurmayı engellemek: üç katman

Arama **hiçbir zaman "bulamadım" demez**; filtreye uyan en yakın parçaları her koşulda döndürür. Skor eşiğiyle ayırmak da işe yaramadı: kapsam dışı bir soru 0,830 puan alırken kapsam içi bir soru 0,826 aldı. Karar zorunlu olarak modele kalıyor — ama prompt kuralı **olasılıksal** bir savunmadır. Bu yüzden tek katman değil üç katman var:

1. **Prompt kuralı + düşük sıcaklık** — modelin uyma olasılığını artırır.
2. **Sabit işaret (`KAYNAK_YOK`)** — model uyduğunda bu **deterministik** olarak yakalanır. Düz metinden "bulamadım" anlamak kırılgan olurdu; sabit bir işaret kararı koda taşıyor.
3. **Ölçüm** — uyma oranı tahmin değil, sayı. Otomatik değerlendirme betiği iki yönlü ölçüyor.

> **Neden iki yönlü ölçüm**
>
> Yalnızca kapsam dışı soruları ölçseydik, "her soruya bulamadım de" diyen bir prompt metriği %100 yapardı ve asistan tamamen işe yaramaz olurdu. Bu yüzden iki oran birlikte anlamlı: **kapsam dışı → reddetmeli**, **kapsam içi → cevaplamalı.**

Takip soruları

"Bununla ilgili bir örnek verir misin?" cümlesinde **hiç içerik kelimesi yok.** Arama bu cümleyi olduğu gibi görürse alakasız sonuçlar döner. Çözüm: soru aramaya gitmeden önce, sohbet geçmişine bakan küçük bir model çağrısıyla **kendi başına anlaşılır hâle getiriliyor.**

Anahtar kelime listesi denendi ve elendi: Türkçe geçmişe sınırsız biçimde atıf yapıyor ("konuyla ilgili", "az önce anlattığın", "aynı konuda") ve liste hiçbir zaman tamamlanmıyor. Ayrıca iki hata zıt yönlere çekiyor — atfı kaçırmak boş arama, yanlış birleştirmek ise **konu değişimini yok etmek** demek.

Sözünü kesebilme (barge-in)

Cevap çalınırken panele basmak cevabı keser ve yeni soruyu başlatır. Bu, gerçek bir konuşmanın olmazsa olmazı; teknik olarak çalışan tur görevinin **iptal edilebilir** olmasını gerektiriyor. Kesilen turun duyulan kısmı hafızada tutuluyor — öğrencinin sonraki sorusu neredeyse her zaman ona atıfta bulunuyor.

5. Donanım

Bileşen	Görevi
ESP32-S3 (8 MB flash, 2 MB PSRAM)	Ana işlemci, Wi-Fi
ILI9341 2.4" dokunmatik ekran	Arayüz, bas-konuş paneli, kurulum ekranı
INMP441 dijital mikrofon	Ses yakalama (I2S)
MAX98357A + 8 Ω hoparlör	Ses çalma (I2S)
XPT2046 dokunmatik denetleyici	Dokunma okuma, kalibrasyon

Cihazda **ses çözücü yok**: backend sıkıştırılmamış ses gönderiyor ve baytlar doğrudan donanıma yazılıyor. Bu, hem gecikmeyi düşürdü hem de cihazdan bütün bir kod katmanını kaldırdı.

Donanımda karşılaşılan sorunlar

Firmware tarafındaki hataların çoğu **yazılımın doğru, fiziksel katmanın eksik** olduğu durumlardı. Üç kez sebep kabloda, bileşende ya da montajdaydı — kod kusursuz görünüyordu.

> **Tekrar eden ders: basit test sinyalleri asimetrik hataları gizler**
>
> Ekran testinde düz renkler kullanıldığında görüntü doğru sanıldı; oysa satır genişliği yanlıştı. Çeyreklere bölünmüş bir desen aynı hatayı **tek bakışta** gösterdi. Aynı şekilde mikrofon testi yalnızca ses seviyesine baktığı için sinyaldeki kaymayı gizledi — hoparlördeki cızırtının sebebi oydu.

6. Ölçülen sonuçlar

Ölçüm	Sonuç
İlk sese kadar geçen süre — *ilk ölçüm*	11.020 ms
İlk sese kadar geçen süre — *akışlı zincir sonrası*	2.697 – 3.777 ms
Hedef	≤ 4.000 ms
Kapsam dışı soruda doğru reddetme	6 / 6
Kapsam içi soruda doğru cevaplama	6 / 6
Otomatik test sayısı	37 (tamamı geçiyor)
İndekslenen metin parçası	8.577

Gecikme dört ardışık koşuda ölçüldü: **2697, 5592, 2717, 3777 ms.** Üçü hedefi karşıladı. Aşan koşuda tek sebep sağlayıcının o anki yavaşlığıydı (dil modelinin ilk kelimesi normalde 600–1000 ms iken 3378 ms'ye çıktı) — yani kendi kodumuzdan kaynaklanmıyordu.

7. Mimari kararlar

Her karar, alternatifleri ve gerekçesiyle birlikte belgelendi. Öne çıkanlar:

Karar	Gerekçe
Modüler monolit	Tek eşzamanlı kullanıcı için mikroservis bölmenin karşılığı yok; tek süreç hem basit hem hızlı.
Bas-konuş	Kayıt ve çalma asla aynı anda olmuyor; bu sayede yankı engelleme gerekmiyor.
Uçtan uca akış	Gecikme hedefinin tek gerçekçi yolu. Cümle sınırında bölüp anında seslendiriyoruz.
İptal edilebilir tur	Söz kesme (barge-in) ancak çalışan işin iptal edilebilmesiyle mümkün.
Sorgu anında sınıf/ders filtresi	Öğrenci profilini değiştirdiğinde yeniden indeksleme gerekmiyor.
Sağlayıcı adapter arayüzleri	STT/LLM/TTS sözleşme arkasında. Sağlayıcı değişimi tek dosya; ayrıca testler **ücretli çağrı yapmadan** koşuyor.
Ayarlar cihaz belleğinde	Wi-Fi ve sunucu adresi ekrandan girilebiliyor; ağ değişince firmware derlemek gerekmiyor.

> **Adapter kararının beklenmedik faydası**
>
> Sağlayıcı bağımsızlığı için tasarlanmıştı. Karşılığını başka yerde verdi: test kredisi bittiğinde bile **turun tamamı test edilebilir kaldı**, çünkü orkestrasyon yalnızca sözleşmelerle konuşuyor.

8. Öne çıkan üç hata ve çıkarılan ders

Aynı değerin iki kaynağı olmamalı

Sunucu adresi iki ayrı yerden okunuyordu: bir yerde derleme zamanı sabitinden, başka bir yerde cihaz belleğinden. Ev ağında ikisi aynı olduğu için sorun uzun süre görünmedi. Ağ değişince **ayrıştılar**: cihaz çalışıyor görünürken bir özellik sessizce bozuldu.

Ölçtüğün havuz doğru havuz mu

Arayüz kütüphanesi bellek yetersizliğinden çöküyordu, ama sistem belleğinde 30 KB boş görünüyordu. Kütüphane o belleği kullanmıyordu — kendi sabit havuzu vardı. **"Bellek var" ölçümü, ölçtüğü havuz yanlışsa hiçbir şey söylemiyor.**

Her katman tek başına doğru olabilir

Dokunmatik ekran çalışmıyordu. Sürücü doğru okuyordu, dönüşüm doğruydu, arayüz nesneleri doğruydu — ama arayüz kütüphanesi kesme pini verildiğinde **yoklamayı bırakıyor**, dokunmatik yonga ise varsayılan ayarda o kesmeyi hiç üretmiyordu. İki makul varsayılan birleşince okuma hiç yapılmıyordu.

9. Mevcut durum

Tamamlanan

- Uçtan uca sesli tur, hedefin altında gecikmeyle
- Kaynağı gösterilen, kitaba dayalı cevaplar
- Takip soruları ve söz kesme
- Cihazdan sınıf/ders seçimi
- Cihazdan Wi-Fi ve sunucu kurulumu
- Yönetim paneli: canlı izleme, geçmiş, ayarlar
- Tarayıcı üzerinden yedek erişim yolu

Bilinen sınırlar

- Tek eşzamanlı kullanıcı (bilinçli kapsam kararı)
- Yerel ağ, şifresiz bağlantı — sınıf ortamı varsayımı
- Panel gerçek bir yetki sınırı değil, tek şifreli kapı
- Bazı belirsiz sorularda cevap doğru ama "kaynak bulunamadı" etiketi yanlış konuyor
- Dokunmatik klavyede Türkçe karakter yok

10. Sunumda gösterilecek akış

1. **Düz soru** — seçili dersten bir konu. Ekranda soru, cevap ve kaynak ünite görünür.
2. **Takip sorusu** — "bununla ilgili bir örnek ver". Atıf çözülür, doğru kaynağa gidilir.
3. **Söz kesme** — cevap konuşurken panele basılır; ses kesilir, yeni soru başlar.
4. **Ders değiştirme** — cihazdan sınıf ve ders seçimi.
5. **Kapsam dışı soru** — sistem uydurmaz, bulamadığını söyler.
6. **Panel** — turun canlı akışı, kaynaklar, gecikmeler ve ayar değişimi.

Bu belge projenin genel hatlarını anlatır. Kararların tam gerekçeleri mimari tasarım dokümanında, ölçümler ve hata çözümlerinin ayrıntısı uygulama planında, demo günü adımları demo kılavuzunda yer alır.